

Raport z Etapu 6: RC, osiągnięte wyniki

Symulacja kolonii mrówek

Autorzy: Jakub Grześ, Tomasz Smyda

2026-05-27

1. Wstęp

Niniejszy raport podsumowuje eksperymenty przeprowadzone w ramach projektu symulacji kolonii mrówek, implementacja dostępna jest na platformie GitHub [1]. Głównym celem ostatniego etapu prac było dostrojenie parametrów modelu inspirowanego zachowaniem feromonowym [2], w taki sposób, aby przebieg symulacji jak najdokładniej odwzorowywał dane referencyjne pochodzące ze zbiorów IndoorDataset oraz OutdoorDataset [3].

Wszystkie uruchomienia wykonano dla 10 sekwencji: 5 ze środowiska zamkniętego (indoor) i 5 ze środowiska otwartego (outdoor). Każdy eksperyment obejmował 1000 iteracji algorytmu Optuna [4], a jego jakość oceniano na podstawie zestawu metryk charakteryzujących zachowanie kolonii w czasie wybranych w poprzednich etapach.

Wyniki osiągnięte przy tym eksperymencie są dostępne w Raports/result_plots/ w repozytorium projektu.

2. Zastosowane metryki

Dobranie odpowiedniego zestawu metryk okazało się dość nieoczywiste. Ostatecznie, metodą prób i błędów, zdecydowaliśmy się na cztery, które w różnym stopniu odzwierciedlają zarówno dynamikę ruchu kolonii, jak i jej zdolność do eksploracji przestrzeni. Tabela 1 prezentuje wybrane metryki wraz z ich opisem oraz przypisanymi wagami w funkcji straty:

Metryka	Znaczenie	Waga w stracie
dispersion	Rozproszenie kolonii względem jej centroidu. Metryka ta opisuje stopień oddalenia mrówek od środka ciężkości grupy.	1.0
mean_displacement	Średnie przemieszczenie względem pozycji początkowej. Obrazuje ogólną aktywność ruchową osobników.	1.0
mean_sinusosity	Średnia krętość trajektorii. Wskazuje, jak bardzo mrówki odchylają się od prostej linii.	0.5
space_coverage	Procentowy udział przestrzeni zajętej przez kolonię. Wskazuje, w jakim stopniu model eksploruje dostępną planszę.	2.0

Waga w stracie oznacza, jak silnie błąd danej metryki wpływa na końcowy loss minimalizowany przez Optunę. Większa waga oznacza większą karę za niedopasowanie tej metryki.

3. Przeprowadzone eksperymenty

Eksperymenty zrealizowano niezależnie dla danych z obu środowisk:

- IndoorDataset: sekwencje od Seq00010bject10Image94 do Seq00050bject10Image94.
- OutdoorDataset: sekwencje od Seq00060bject21Image64 do Seq00100bject30Image64.

Tym samym uwzględniono wszystkie sekwencje dostępne w wykorzystanym zbiorze danych [3].

Każdy scenariusz był optymalizowany niezależnie. Dla każdego zestawu rejestrowano wartość funkcji straty przed optymalizacją (baseline loss), najlepszy uzyskany wynik po optymalizacji (best loss), procentową poprawę oraz optymalne parametry wyznaczone przez bibliotekę Optuna.

3.1. Baseline i sposób liczenia poprawy

W raporcie przez baseline rozumiemy wynik symulacji uruchomionej z domyślnymi parametrami modelu, czyli bez wcześniejszego dostrajania przez Optunę. Taki wynik pełni rolę punktu odniesienia.

$$\text{improvement_pct} = \left(\frac{\text{baseline_loss} - \text{best_loss}}{\text{baseline_loss}} \right) \cdot 100\%$$

3.2. Optymalizowane parametry modelu

W każdym uruchomieniu Optuna przeszukiwała przestrzeń parametrów sterujących zachowaniem symulowanych mrówek. Parametry obejmowały mechanizm feromonowy, losowość ruchu, geometrię sensorów oraz proste oddziaływania grupowe.

Parametr	Znaczenie
pheromone_deposit	ilość feromonu zostawiana przez mrówkę w środowisku
evaporation_rate	tempo zanikania feromonu w kolejnych krokach symulacji
turn_strength	siła skrętu wynikająca z różnicy poziomu feromonu po lewej i prawej stronie
noise_strength	losowy składnik ruchu zwiększający niedeterministyczność trajektorii
sensor_distance	odległość, z której mrówka odczytuje poziom feromonu
sensor_angle	kąt rozstawienia sensorów względem aktualnego kierunku ruchu
pheromone_delay	opóźnienie depozycji feromonu ograniczające natychmiastowe podążanie za własnym śladem
cohesion_strength	siła przyciągania mrówki w stronę centroidu grupy
separation_strength	siła oddalania się od grupy, gdy mrówka znajduje się zbyt blisko innych
preferred_group_distance	preferowany dystans względem grupy używany w mechanizmie kohezji i separacji
step_size_min	minimalna długość kroku pojedynczej mrówki
step_size_max	maksymalna długość kroku pojedynczej mrówki

Tabela 2: Przestrzeń parametrów przeszukiwana przez Optunę.

4. Wyniki

Zbiorcze podsumowanie wyników dla wszystkich uruchomień prezentują kolejno Tabela 3 oraz Tabela 4.

Zbiór danych (uśrednione)	Śr. Baseline loss	Śr. Best loss	Śr. Poprawa
Indoor Dataset (5 sekwencji)	0.2707	0.1604	31.99%
Outdoor Dataset (5 sekwencji)	0.1950	0.1111	36.76%
Średnia (10 sekwencji)	0.2329	0.1358	34.38%

Tabela 3: Globalne podsumowanie procesu optymalizacji parametrów symulacji.

Zbiór danych	Najlepsza sekwencja	Wynik	Najslabsza sekwencja	Wynik
Indoor Dataset	Seq00020bject10Image94	64.01%	Seq00010bject10Image94	8.44%
Outdoor Dataset	Seq00070bject26Image64	71.51%	Seq00060bject21Image64	13.53%

Tabela 4: Zestawienie skrajnych przypadków (ekstremów) w podziale na środowiska.


Kluczowe wnioski płynące z przeprowadzonych testów:

- Zastosowanie optymalizatora przyniosło poprawę wyników we wszystkich 10 sekwencjach, przy czym średnia redukcja błędu wyniosła 34.38%.
- Zbiór outdoor charakteryzował się lepszym uśrednionym wynikiem niż zbiór indoor.
- Najlepszy jednostkowy rezultat odnotowano dla sekwencji Seq00070bject26Image64 z zestawu OutdoorDataset, gdzie poprawa wyniosła aż 71.51%.
- Najslabszy wynik zanotowano w przypadku Seq00010bject10Image94 (IndoorDataset), jednak tu również osiągnięto poprawę w porównaniu do ustawień bazowych.


5. Wizualizacja wyników

Wyniki liczbowe uzupełniono wykresami, które zostały wygenerowane automatycznie po zakończeniu procesu dopasowania. W niniejszym rozdziale zaprezentowano przykładowe wizualizacje dla sekwencji o najlepszych wynikach z obu środowisk (Seq00020bject10Image94 dla indoor oraz Seq00070bject26Image64 dla outdoor).

5.1. Historia optymalizacji Optuny



Indoor: Seq00020bject10Image94




Outdoor: Seq00070bject26Image64


Rysunek 1: Historia przebiegu optymalizacji za pomocą biblioteki Optuna dla reprezentatywnych sekwencji indoor i outdoor.

Rysunek 1 ilustruje ewolucję wartości funkcji celu w kolejnych iteracjach optymalizatora. Analiza tych wykresów ułatwia ocenę, czy przypisany budżet obliczeniowy (liczba prób) był wystarczający do zbiegnięcia algorytmu i czy zwiększenie liczby iteracji mogłoby przynieść dalszą poprawę wyników.


5.2. Porównanie metryk dla sekwencji indoor




Dyspersja



Średnie przemieszczenie



Krętość trajektorii




Pokrycie przestrzeni

Rysunek 2: Zestawienie metryk ruchu dla danych rzeczywistych oraz symulacji po dostrojeniu parametrów dla sekwencji indoor.

Jak widać na Rysunek 2, symulacja nie zdołała dobrze odwzorować metryk. Może to wynikać z faktu, że w środowisku indoor ruch jest bardziej ograniczony, a model nie jest do tego przystosowany.

5.3. Porównanie metryk dla sekwencji outdoor



Rysunek 3: Zestawienie metryk ruchu dla danych rzeczywistych oraz symulacji po dostrojeniu parametrów dla sekwencji outdoor.

Rysunek 3 przedstawia analogiczne zestawienie dla najlepszej sekwencji z zestawu outdoor. Dopasowanie wybranych metryk jest lepsze niż dla indoor, szczególnie dla dyspersji i średniego przemieszczenia. Nadal widoczne jest jednak zbyt małe pokrycie przestrzeni.

W obu analizowanych przypadkach dopasowanie space_coverage pozostaje najsłabszym elementem. Może to wynikać z ograniczonej elastyczności modelu oraz zbyt dużej zależności od mechanizmu feromonowego, który nie jest w stanie w pełni oddać złożoności zachowań mrówek w rzeczywistych warunkach.

6. Podsumowanie

Średnia poprawa wynosząca 34.38% w obrębie całego zestawu danych wskazuje, że domyślne parametry symulacji wymagały kalibracji. Środowiska outdoor okazały się bardziej podatne na optymalizację, co sugeruje, że model lepiej radzi sobie z mniej ograniczonymi warunkami ruchu. Z kolei słabsze wyniki w środowisku indoor mogą wskazywać na potrzebę wprowadzenia dodatkowych mechanizmów adaptacyjnych, które pozwoliłyby symulacji lepiej reagować na ciasne przestrzenie i przeszkody.

Projekt osiągnął zamierzony cel częściowo: udało się zbudować powtarzalny pipeline optymalizacji i uzyskać poprawę funkcji straty dla wszystkich sekwencji, jednak analiza wykresów pokazuje, że model nadal nie odwzorowuje w pełni wszystkich aspektów ruchu kolonii. Dalsze eksperymenty mogłyby obejmować porównanie kilku wariantów modelu, lepszy dobór metryk oraz wprowadzenie dodatkowych mechanizmów opisujących eksplorację przestrzeni.

Bibliografia

- [1] J. Grześ i T. Smyda, „Ant-Colony-Simulation”. [Online]. Dostępne na: <https://github.com/jgrzes/Ant-Colony-Simulation>

- [2] A. Perna *et al.*, „Individual Rules for Trail Pattern Formation in Argentine Ants (*Linepithema humile*)”, *PLoS Computational Biology*, t. 8, nr 7, s. e1002592, lip. 2012, doi: 10.1371/journal.pcbi.1002592.
- [3] X. Cao, „ANTS–ant detection and tracking”. [Online]. Dostępne na: <https://data.mendeley.com/datasets/9ws98g4npw/4>
- [4] T. Akiba, S. Shotajiro, T. Yanase, T. Ohta, i M. Koyama, „Optuna: A Next-generation Hyperparameter Optimization Framework”, w *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019, s. 2623–2631.